

지정학적 리스크를 반영한 원자재 이상 변동 감지 및 가격 예측

제출 3 - 반복 수정 (Feature 엔지니어링 + SMOTE + 튜닝)

머신러닝 학기 프로젝트

조장 : 20232501 임태후 조원 : 20232514 유종현

1. 개요 - 2주차 한계와 3주차 개선 방향

2주차에서는 5개 모델(Random Forest, Logistic Regression, SVM, XGBoost, KNN)을 TimeSeriesSplit 5-Fold로 비교한 결과, F1-Score는 모두 0.21~0.35 범위에 머물렀다. 특히 Recall이 모든 모델에서 0.15~0.32 수준으로 낮아, 실제 이상변동의 약 70%를 감지하지 못하는 상태였다. 3주차에서는 이 한계를 다음 세 축으로 개선하였다.

2주차 한계	3주차 개선 방법	기대 효과
당일 값만 사용 (Feature 7개)	Lag(1·3·5일), 이동평균(MA5·MA20), 변동성(20일), RSI(14) 추가 → 23개	지연된 시장 반응과 추세·변동성 정보 반영
클래스 불균형 (이상 35.5%) - Recall 저조	SMOTE로 학습 데이터에서 소수 클래스를 합성 오버샘플링	Recall 개선 (놓치는 이상변동 감소)
기본 하이퍼파라미터 사용	GridSearchCV(내부 TimeSeriesSplit 3-Fold)로 XGBoost 파라미터 탐색	모델 성능의 상한 확인

데이터: 1538일 (정상 991일 / 이상 547일, 이상변동 비율 35.6%). 비교 조건은 동일한 TimeSeriesSplit 5-Fold이며, 2주차 조건은 'Feature 7개 + SMOTE 미적용', 3주차 조건은 'Feature 23개 + SMOTE 적용'으로 통제하여 변화의 원인을 명확히 분리했다.

2. 추가 Feature 상세 설명

3주차에서 새로 추가한 16개 Feature는 4개 카테고리로 구성된다. 각 카테고리는 서로 다른 가설을 검증하기 위해 설계되었으며, 본 절에서는 각 Feature의 정의, 계산 방법, 그리고 추가 이유를 정리한다.

2.1 Feature 전체 구성 (총 23개)

카테고리	개수	Feature 목록
기본 (2주차부터)	7	VIX, GPR지수, GPR_실제행동, GPR_위험, 금_수익률, 천연가스_수익률, 은_수익률
시차 (Lag)	9	VIX_lag(1·3·5), GPR_lag(1·3·5), 원유수익률_lag(1·3·5)
이동평균	4	원유_MA5, 원유_MA20, VIX_MA5, MA_ratio
변동성	2	변동성_20d, VIX_변동성_20d
모멘텀	1	RSI_14

2.2 시차 (Lag) Feature - 9개

가설: 시장 충격은 당일에 모두 반영되지 않고 며칠 동안 여진이 이어진다. 예를 들어 전쟁 발발 다음 날에도 공급 우려로 추가 변동이 발생하는 경우가 많다.

계산: `shift(n)`으로 `n`일 전 값을 오늘의 Feature로 사용

```
df['VIX_lag1'] = df['VIX'].shift(1) # 어제의 VIX
```

1·3·5일을 선택한 이유:

- 1일: 직전일 효과 (가장 즉각적인 시장 반응)
- 3일: 단기 누적 반응 (주 중반 무렵의 시장 흐름)
- 5일: 1주일 효과 (시장이 한 사이클 돌고 난 후 잔존 영향)

2.3 이동평균 Feature - 4개

가설: 일별 노이즈를 제거하고 추세(trend) 정보를 모델에 직접 제공하면 이상변동의 시점 파악에 유리하다.

Feature	정의	의미
원유_MA5	최근 5일 종가 평균	단기 추세 (1주일)
원유_MA20	최근 20일 종가 평균	장기 추세 (1개월)
VIX_MA5	최근 5일 VIX 평균	시장 불안의 단기 추세
MA_ratio	원유_MA5 / 원유_MA20	MA_ratio > 1 상승추세 / < 1 하락추세

특히 MA_ratio는 트레이딩의 '골든크로스/데드크로스'를 수치화한 변수로, 단기와 장기 추세의 상대적 위치를 한 숫자로 표현한다. Feature 중요도 분석에서 상위 3위를 기록했다.

2.4 변동성 Feature - 2개 (Top 1, 2위 차지)

가설: 변동성이 큰 시기에는 큰 변동이 군집해서 발생한다 (변동성 클러스터링, GARCH 모델의 핵심 가정). 따라서 최근 변동성 자체가 이상변동 발생을 예측하는 가장 강력한 신호 중 하나가 된다.

Feature	정의	수치 의미
변동성_20d	최근 20일 원유 수익률의 표준편차	1.5 = 평온 / 4.0 이상 = 폭풍
VIX_변동성_20d	최근 20일 VIX의 표준편차	VIX 자체가 흔들리는 정도 (시장 합의 결여)

이상변동 정의 자체가 " $|수익률| \geq 2\%$ "이므로, 최근 변동성과 직접적으로 연관된다. Feature 중요도 분석에서 변동성_20d(0.104)가 1위, VIX_변동성_20d(0.052)가 2위를 차지한 것은 이론적 가설을 데이터가 직접 확인한 결과이다.

2.5 모멘텀 Feature - RSI(14)

RSI(Relative Strength Index): 14일 동안 상승일의 평균 상승폭과 하락일의 평균 하락폭의 비율을 0~100 사이로 표준화한 지표.

$$RSI = 100 - 100 / (1 + \text{평균상승} / \text{평균하락})$$

해석 기준:

- 70 이상: 과매수 (너무 올랐음 → 차익실현 매도로 급락 가능성)
- 30 이하: 과매도 (너무 떨어졌음 → 반등 매수로 급등 가능성)
- 50 근처: 중립 (방향성 약함)

가설: 이상변동은 종종 극단 상태(과매수/과매도)에서 발생한다. RSI는 이러한 극단 상태를 한 변수로 요약한다.

2.6 카테고리별 검증 가설 요약

Feature 카테고리	검증하려는 가설
시차 (Lag)	어제의 시장 충격이 오늘 이상변동에 영향을 주는가?
이동평균	단기/장기 추세 차이가 이상변동의 신호인가?
변동성	변동성이 큰 시기에 더 큰 이상변동이 따라오는가? (변동성 클러스터링)
RSI (모멘텀)	과매수/과매도 극단 상태가 이상변동 직전 상태인가?

2.7 결과 요약: Top 5 중요도가 모두 신규 Feature

순위	Feature	Importance	카테고리
1	변동성_20d	0.104	변동성 (신규)
2	VIX_변동성_20d	0.052	변동성 (신규)
3	MA_ratio	0.050	이동평균 (신규)
4	원유수익률_lag3	0.047	시차 (신규)
5	원유수익률_lag1	0.046	시차 (신규)

→ XGBoost가 학습한 결과, 가장 중요한 5개 Feature가 모두 3주차에 새로 추가한 변수였다. 이는 모델이 "당일 값"보다 "최근 흐름·변동성·시차 정보"를 더 신뢰한다는 의미이며, Feature 엔지니어링이 Recall 개선의 핵심 동력이었음을 직접적으로 보여준다.

3. 모델 비교표 (2주차 vs 3주차)

3.1 모델별 평균 성능 (TimeSeriesSplit 5-Fold)

모델	조건	Accuracy	Precision	Recall	F1-Score
Random Forest	2주차	0.649	0.449	0.243	0.304
	3주차	0.659	0.485	0.349	0.379
Logistic Regression	2주차	0.673	0.416	0.149	0.209
	3주차	0.593	0.310	0.413	0.347
SVM	2주차	0.659	0.423	0.200	0.268
	3주차	0.603	0.409	0.505	0.435
XGBoost	2주차	0.623	0.408	0.320	0.352
	3주차	0.650	0.473	0.379	0.413
KNN	2주차	0.598	0.377	0.311	0.337
	3주차	0.536	0.333	0.446	0.370


3.2 지표별 변화량 (3주차 - 2주차)

모델	Δ Accuracy	Δ Precision	Δ Recall	Δ F1
Random Forest	↑ 0.010	↑ 0.036	↑ 0.106	↑ 0.075
Logistic Regression	↓ 0.080	↓ 0.106	↑ 0.264	↑ 0.138
SVM	↓ 0.055	↓ 0.014	↑ 0.306	↑ 0.167
XGBoost	↑ 0.027	↑ 0.065	↑ 0.059	↑ 0.060
KNN	↓ 0.062	↓ 0.045	↑ 0.135	↑ 0.033

→ Recall 1위: SVM (0.505), F1 1위: SVM (0.435). 5개 모델 모두 Recall이 상승하였으며, F1도 4개 모델에서 상승하였다.

4. 성능 그래프


4.1 4대 지표 비교 (모델 × 주차)



각 모델별로 2주차(회색)와 3주차(파랑)의 4대 지표를 비교한 결과, Precision·Recall·F1에서 전반적으로 3주차의 막대가 더 길다. Accuracy는 일부 모델에서 하락했는데, 이는 SMOTE로 인해 소수 클래스 예측 비중이 늘면서 다수 클래스(정상) 예측 정확도가 일부 희생되었기 때문이다.


4.2 Recall 집중 비교 (이상변동 감지율)

3주차 핵심 목표인 Recall만 따로 비교하였다. 5개 모델 전부 Recall이 상승하였다.




4.3 Fold별 F1-Score 변화 (3주차 안정성)

TimeSeriesSplit 5-Fold 각각에서의 F1을 그렸다. 학습 데이터가 늘어나는 Fold 4~5에서 대부분의 모델이 더 높은 F1을 보이며, 이는 새로운 Feature가 많은 데이터에서 더 잘 작동함을 시사한다.




4.4 ROC 커브 비교 (마지막 Fold)



확률 예측 기반 분류 성능을 보여준다. AUC가 1에 가까울수록 우수하며, 0.5는 무작위 추정이다. 3주차 Feature 확장 후 대부분 모델의 AUC가 0.6 이상으로 확보되었다.

4.5 Feature 중요도 (튜닝된 XGBoost)



Top 3: 변동성_20d(0.104), VIX_변동성_20d(0.052), MA_ratio(0.050). 주목할 점은 상위 중요도 Feature가 모두 3주차에 새로 추가된 변수라는 것이다. 이는 시차/변동성/추세 정보가 이상변동 감지에 실질적으로 기여함을 의미하며, Feature 엔지니어링이 효과적이었다는 직접적 증거이다.

5. 변화 원인 분석

5.1 무엇이 바뀌었는가 (3가지 변화)

변화	구체적 내용	영향을 주는 지표
① Feature 확장	7개 → 23개 (Lag·MA·변동성·RSI 추가)	Precision, Recall, F1
② SMOTE 오버샘플링	학습 데이터에서 이상변동 합성 (테스트는 원본 분포 유지)	Recall (주), Accuracy (희생)
③ XGBoost 튜닝	GridSearchCV로 n_estimators·max_depth·learning_rate 탐색	F1, ROC-AUC

5.2 변화별 세부 원인 분석

(1) Recall이 전체적으로 상승한 이유 - SMOTE 효과

2주차에서는 정상(64.5%) vs 이상(35.5%)의 불균형으로 모델이 '정상' 쪽으로 편향되어 이상변동을 놓치는 경향이 있었다. SMOTE는 학습 데이터에서 소수 클래스(이상변동)의 주변에 합성 데이터를 만들어 클래스 비율을 1:1로 균형 잡는다. 그 결과 모델이 이상변동 패턴을 더 적극적으로 학습하게 되어 Recall이 상승했다. 가장 극적인 변화는 SVM(0.200→0.505, +0.305)과 Logistic Regression(0.149→0.413, +0.264)에서 나타났는데, 이 두 모델은 결정경계가 단순해 클래스 불균형의 영향을 더 크게 받기 때문이다.

(2) 일부 모델에서 Accuracy가 하락한 이유 - Precision-Recall Trade-off

Accuracy는 정상/이상 모두를 종합한 정확도이다. SMOTE로 모델이 이상변동을 더 적극적으로 예측하게 되면서, 실제로는 정상인데 이상으로 잘못 예측하는 사례(FP)가 일부 늘어났다. 그 결과 정상 클래스의 정확도가 떨어지고 전체 Accuracy가 낮아진다. 이는 의도된 trade-off로, 이상변동 감지가 목적인 본 프로젝트에서는 Accuracy 약간의 하락보다 Recall 개선이 훨씬 중요하다.

(3) F1이 4개 모델에서 상승한 이유 - Feature 확장 효과

F1은 Precision과 Recall의 조화평균이다. SMOTE만으로는 Recall은 오르지만 Precision이 내려가 F1이 그대로일 수 있다. 그러나 새로 추가한 Lag/MA/변동성/RSI Feature가 이상변동의 예측 패턴을 더 잘 포착하면서 Precision도 함께 유지되거나 상승했다. Feature 중요도 Top 3가 모두 신규 변수(변동성_20d, VIX_변동성_20d, MA_ratio)라는 사실이 이를 뒷받침한다.

(4) XGBoost 튜닝 결과 - 단일 모델로 도달한 최고 성능

조건	Accuracy	Precision	Recall	F1	ROC-AUC
2주차 XGBoost (기본 파라미터, Feature 7개)	0.623	0.408	0.320	0.352	-
3주차 XGBoost (기본 파라미터, Feature 23개 + SMOTE)	0.650	0.473	0.379	0.413	-
3주차 XGBoost (튜닝 후, 마지막 Fold 평가)	0.723	0.519	0.384	0.441	0.648

최적 파라미터: `n_estimators=200`, `max_depth=6`, `learning_rate=0.1`. 튜닝 후 F1 0.441로, 1주차 단일 모델 0.393 → 2주차 5-Fold 평균 0.352 → 3주차 튜닝 후 0.441로 개선되었다.

5.3 1·2·3주차 통합 성능 추이 (XGBoost 기준)

주차	조건	Accuracy	Precision	Recall	F1
1주차	Random Split, RF	0.683	0.640	0.283	0.393
2주차	TimeSeriesSplit, XGB(기본)	0.623	0.408	0.320	0.352
3주차	+ Feature 23개 + SMOTE + 튜닝	0.723	0.519	0.384	0.441

주의: 1주차 성능은 Random Split으로 인한 데이터 누출이 포함되어 부풀려진 수치이다. 공정한 비교는 2주차→3주차 사이에서 이루어지며, Recall은 0.320 → 0.384 (+0.063), F1은 0.352 → 0.441 (+0.089)로 개선되었다.

5.4 남은 한계

3주차 개선에도 불구하고 Recall은 여전히 50% 수준에 머무르며, 이상변동의 절반 가까이는 감지되지 않는다. 이는 다음 한계에서 비롯된 것으로 분석된다.

- 이상변동 기준이 $\pm 2\%$ 고정 → 시기별 변동성 차이를 반영하는 적응형 임계값 필요
- 외부 데이터 부족 → 뉴스 텍스트, 산유국 OPEC 결정 등 비정형 데이터 미반영
- 단일 임계값 0.5 사용 → 사용 목적(위험경보 vs 매수추천)에 따라 분리된 임계값 적용 여지

부록: 사용 도구 및 환경

항목	내용
프로그래밍 언어	Python 3.9
데이터	commodity_vix_gpr_data.xlsx (1538일)
모델	scikit-learn (RF, LR, SVM, KNN), XGBoost
오버샘플링	imbalanced-learn SMOTE
하이퍼파라미터 튜닝	GridSearchCV (TimeSeriesSplit 3-Fold 내부 검증)
교차검증	TimeSeriesSplit 5-Fold (외부 평가)
전처리	StandardScaler
시각화	matplotlib (AppleGothic 폰트)